

Teilautomatisierte Erfassung und Nachverfolgung des Eisbergs A23a von Januar 2022 bis Juni 2024 mittels Sentinel 1-SAR Daten

Bachelorarbeit

vorgelegt von:

Tim Lehmann

Matrikelnummer: 503417

Studiengang: Bachelor Geoinformatik

Erstgutachter:

Dr. Torsten Prinz

Zweitgutachter:

Dr. Jan R.K. Lehmann

Münster, 2. Oktober 2024

Inhaltsverzeichnis

1	Einleitung	1
1.1	Motivation & Zielsetzung	1
1.2	Aufbau	1
1.3	Verwandte Arbeiten	2
2	Grundlagen	3
2.1	Radio Detection and Ranging	3
2.2	Synthetic Aperture Radar	3
2.3	Sentinel 1 Mission	6
2.3.1	Level 0	7
2.3.2	Level 1	7
2.3.3	Level 2	7
2.3.4	Level 3	7
2.4	Forschungsbereich	8
2.5	Google Earth Engine	8
2.6	QGIS	9
2.7	Orfeo Toolbox	9
3	Methodik	11
3.1	Sentinel 1 Preprocessing Workflow	11
3.1.1	Apply Orbit File	12
3.1.2	Thermal Noise Removal	12
3.1.3	Border Noise Removal	12
3.1.4	Calibration	12
3.1.5	Speckle Filtering	12
3.1.6	Range Doppler Terrain Correction	12
3.1.7	Conversion to dB	12
3.2	Large Scale Mean Shift	13
3.2.1	Smoothing	13
3.2.2	Segmentation	13
3.2.3	Small Region Merging	13
3.2.4	Vectorization	13
3.3	Machine Learning	14
3.3.1	Random Forest	14
3.4	Trainingsdaten	15
3.5	Validierungsmethoden	15
3.5.1	Accuracy	15

4 Implementierung	17
4.1 Automation Datenbeschaffung GEE Skript	17
4.2 Vorauswahl Bilder	18
4.3 Preprocessing Sentinel 1	19
4.4 Large Scale Mean Shift	19
4.5 Trainingsdatenbeschaffung	20
4.6 Klassifikation	21
4.7 Berechnungen	22
4.7.1 Flächeninhalt	22
4.7.2 Schmelzrate	22
4.7.3 Zentrum	22
4.7.4 Zurückgelegte Distanz	22
5 Ergebnisse & Analyse	23
5.1 Verfolgungskarte	23
5.2 Tabellen	24
5.2.1 Flächeninhalt	24
5.2.2 Schmelzrate	25
5.2.3 Zurückgelegte Distanz	26
6 Diskussion	27
7 Abschluss	29
7.1 Fazit	29
7.2 Ausblick	29
8 Anhang	31

1 Einleitung

1.1 Motivation & Zielsetzung

Die Auswirkungen des Klimawandels führen in der Antarktis zu einem beschleunigten Abschmelzen des Schelfeises. Das Schelfeis stabilisiert das Inlandeis und sorgt dafür, dass es nicht weiter ins Meer rutscht. Zusätzlich reflektiert das Schelfeis die Sonnenstrahlen und kühlt das Wasser. Durch die Erwärmung des Meerwassers schmilzt das Schelfeis und beschleunigt somit den Temperaturanstieg des Meerwassers, was wiederum zu einem globalen Anstieg des Wasserpegels führt [\[1\]](#) [\[2\]](#).

Da der Klimawandel nicht abrupt gestoppt werden kann, ist zu erwarten, dass durch das Abschmelzen des Schelfeises große Eisberge vom Inlandeis abbrechen. Im Jahr 1986 löste sich der weltgrößte Eisberg A23a vom Filchner-Schelfeis und verkeilte sich rund 200 Kilometer von seiner Abbruchstelle entfernt. Mit dem Einsetzen der Schmelzprozesse setzte er sich ab 2020 langsam wieder in Bewegung. Seit März 2023 hat sich seine Geschwindigkeit deutlich erhöht [\[3\]](#) [\[4\]](#).

Die Forschungsfragen zu der Bachelorarbeit sind:

1. Inwiefern können Sentinel 1-SAR Daten genutzt werden, um einen Eisberg zu beobachten und zu kartieren?
2. Wie lassen sich Eisberge in QGIS automatisch visualisieren?
3. Welche Erkenntnisse können aus den Daten über die Flächenberechnung, die Schmelzrate, die Bestimmung des Zentrums des Eisberges und die zurückgelegte Distanz gewonnen werden?

1.2 Aufbau

Die Arbeit ist in sieben Kapitel gegliedert. Am Anfang werden die Grundlagen zur Datenbeschaffung mit Sentinel 1-SAR Daten erklärt und die verwendeten technischen Hilfsmittel vorgestellt. Danach folgt der Methodikteil, in dem die eingesetzten Funktionen und Algorithmen erläutert werden. Anschließend werden die beschriebenen Schritte in der Implementierung angewendet. Im Ergebnisteil werden die Endergebnisse präsentiert. Nach der Analyse der Ergebnisse werden diese in Bezug auf die Forschungsfragen diskutiert. Zum Schluss fasst die Arbeit die wichtigsten Erkenntnisse zusammen und gibt einen Ausblick auf weitere Forschungen.

1.3 Verwandte Arbeiten

In der Forschung gibt es bereits ähnliche Arbeiten zur Erfassung und Verfolgung von Eisbergen mit Sentinel 1-SAR Daten. In einer Arbeit wurde bereits der Eisberg A68 untersucht. Hierbei wurden dessen Schmelzrate sowie das Bewegungsmuster analysiert [5].

Eine weitere verwandte Arbeit beschäftigte sich mit der automatisierten Erkennung und Verfolgung von mittelgroßen bis großen Eisbergen, welche auch mit Sentinel 1-SAR Daten erkannt werden. Die Autoren nutzten die Google Earth Engine, um die Daten effizient zu verarbeiten. Sie entwickelten einen Algorithmus, der Eisberge genau identifizieren und ihre Bewegung über die Zeit hinweg verfolgen kann [6].

2 Grundlagen

Im folgenden Kapitel werden die Grundlagen zur Datenbeschaffung mit Sentinel 1-SAR Daten und die verwendeten technischen Hilfsmittel erklärt.

2.1 Radio Detection and Ranging

Radio Detection and Ranging (RADAR) ist ein aktives Fernerkundungssystem, das auf der Aussendung und dem Empfang elektromagnetischer Wellen basiert. Diese Technologie wird eingesetzt, um die Position, Geschwindigkeit und andere charakteristische Eigenschaften von Objekten zu bestimmen. Das grundlegende Funktionsprinzip von RADAR besteht darin, dass ein Transmitter elektromagnetische Wellen aussendet, die von einem Objekt reflektiert und von einem Empfänger wieder aufgenommen werden. Die Zeitdifferenz zwischen Aussendung und Empfang der Wellen ermöglicht die Berechnung der Entfernung des Objekts. Die RADAR-Gleichung [2.1](#) spielt eine zentrale Rolle bei der Berechnung der vom Empfänger aufgenommenen Signalstärke. Diese Gleichung berücksichtigt verschiedene Faktoren: die Empfangsleistung (W_r), die Sendeleistung (W_t), der Antennengewinn (G), die effektive Apertur der Empfangsantenne (A), der Streuquerschnitt (σ), die Entfernung zwischen Sender und Empfänger (d) und die Oberfläche einer Kugel mit dem Radius d ($4 \times \pi \times d^2$). Sie dient als Grundlage für das Design und die Leistungsbewertung von RADAR-Systemen [\[7\]](#).

$$W_r = \frac{W_t \times G \times A \times \sigma}{(4 \times \pi \times d^2)^2} \quad \text{[8]} \quad (2.1)$$

Radarsensoren finden in vielen Bereichen Anwendung, beispielsweise in der Luft- und Schifffahrt, der Wettervorhersage und der militärischen Überwachung. Ein spezielles Anwendungsgebiet ist das Synthetic Aperture Radar (SAR), das hochauflösende Bilder der Erdoberfläche erzeugt und insbesondere in der Geowissenschaft und Fernerkundung von Bedeutung ist [\[9\]](#).

2.2 Synthetic Aperture Radar

Mit einem Synthetic Aperture Radar (SAR) System können hochauflösende Tag- und Nacht- sowie wetterunabhängige Bilder für eine Vielzahl von Anwendungen, wie beispielsweise die Erforschung des Klimawandels erstellt werden. Heute werden mehr als 15 weltraumgestützte SAR Systeme eingesetzt [\[10\]](#).

2 Grundlagen

Ein SAR System besteht aus einzelnen Parametern, die alle das Endresultat beeinflussen.

Es gibt verschiedene Frequenzbänder mit denen unterschiedliche Arten von Radarstrahlungen gesendet und empfangen werden. Die Frequenzbänder unterscheiden sich anhand ihrer Wellenlänge und Frequenz und lassen sich so gruppieren. Jedes Frequenzband hat dabei Vor- sowie Nachteile, weshalb sich die Anwendungsbereiche für jedes Band unterscheiden. Die aktuell eingesetzten Frequenzbänder sind in der Tabelle 2.1 aufgelistet [8]. Während das Band P durch seine längere Wellenlänge tiefer in den Boden eindringen kann und somit für geophysikalische und biometrische Untersuchungen verwendet wird wird das Band Ka für präzise Details in Trockengebieten oder für die städtische Kartierung verwendet. Verallgemeinert bedeutet eine kleinere Wellenlänge eine genauere Kartierung, welche allerdings anfälliger für atmosphärische Störungen ist [11].

Band	Wellenlänge [cm]	Frequenz [GHz]
P	30 - 100	0.3 - 1
L	15 - 30	1 - 2
S	7.5 - 15	2 - 4
C	3.75 - 7.5	4 - 8
X	2.5 - 3.75	8 - 12
Ku	1.67 - 2.5	12 - 18
K	1.11 - 1.67	18 - 27
Ka	0.75 - 1.11	27 - 40

Tabelle 2.1: Bänder der SAR Systeme mit Wellenlänge und Frequenz [8]

Die Polarisation beschreibt, wie die elektromagnetischen Wellen ausgesendet und empfangen werden. Hierbei gibt es verschiedene Polarisationsarten. Die Linearpolarisation wird unterteilt in HH und VV und die Kreuzpolarisation wird unterteilt in HV und VH. Hier steht jeweils der erste Buchstabe für das Ausenden und der zweite Buchstabe für das Empfangen der elektromagnetischen Wellen. H steht für Horizontal und V für Vertikal. Die HH-Polarisation wird bevorzugt eingesetzt, um einen deutlichen Kontrast zwischen natürlichen und von Menschen geschaffenen Objekten darzustellen. Aus diesem Grund findet sie häufig Anwendung in Bereichen wie der Grenzüberwachung und der Erkennung von beweglichen Zielen. Die VV-Polarisation hingegen wird für die Untersuchung von Texturmerkmalen eingesetzt, beispielsweise bei der Überwachung von Vegetation oder für maritime Anwendungen [8].

In einem RADAR-System enthält das empfangene Signal immer einen gewissen Anteil von intern erzeugtem Rauschen, welches durch elektrische Verluste oder die Gerätetemperatur entsteht. Mit der Formel [2.2](#) wird die Leistungsfähigkeit eines Instruments abgebildet, welches den Nutzen eines Systems bestimmt.

$$\text{SNR} = \frac{\text{Signal of Interest}}{\text{Unwanted Signal}} \quad [8] \quad (2.2)$$

SNR steht für Signal-to-Noise Ratio und wenn dieser Wert unter 1 liegt, dann bedeutet dies, dass mehr Rauschen als Signal empfangen wird. Dementsprechend ist ein hoher SNR Wert gleichbedeutend für eine gute Systemleistung [\[8\]](#).

Die Looks oder Sichten beziehen sich auf die Anzahl der unabhängigen Beobachtungen, die auf das gleiche Gebiet angewendet werden. Es wird unterschieden zwischen Single-Look Bildern, welche die höchste Auflösung, aber auch das meiste Rauschen besitzen und den Multi-Look Bildern, welche durch mehrere Beobachtungen zwar ein geringeres Rauschen, allerdings auch eine schlechtere Auflösung besitzen [\[8\]](#).

Die Bandbreite bezeichnet den Frequenzbereich, den das RADAR System zur Übertragung und zum Empfang von Signalen benutzt [2.1](#). Eine breitere Bandbreite ermöglicht eine präzisere Darstellung von Details, jedoch ist diese auch anfälliger für Rauschen und ineffizienter im Stromverbrauch. Im Gegensatz dazu ist eine geringere Bandbreite energieeffizienter und weniger störanfällig, allerdings auch begrenzter in der Datenübertragungsrate [\[8\]](#).

Der Einfallswinkel beeinflusst das Rückstreuungsverhalten eines SAR-Systems. Bei einem kleineren Einfallswinkel kommt es zu einer erhöhten Rückstreuung, was meistens durch die sogenannte corner reflection verursacht wird. Wenn der Einfallswinkel größer ist nimmt die Rückstreuung ab, da das Signal von der Erdoberfläche weggestreut wird [\[8\]](#).

Größere Antennen ermöglichen eine bessere azimutale Auflösung, da sie mehr Signale sammeln und eine präzisere Detailerfassung ermöglichen. Kleinere Antennen hingegen sind kompakter und leichter, was insbesondere bei weltraumgestützten Systemen von Vorteil ist. Der Nachteil kleinerer Antennen wird durch die Bewegung des Trägers kompensiert, um eine synthetische Apertur zu erzeugen. Die Größe der Antenne ist auch von der Betriebsfrequenz abhängig: Höhere Frequenzen erfordern kleinere Antennen, während niedrigere Frequenzen größere Antennen benötigen, um eine ausreichende Auflösung zu gewährleisten [\[8\]](#).

Der Abbildungsmodus bezieht sich auf verschiedene Betriebsmodi von SAR-Systemen, um verschiedene Anforderungen an Auflösung und Abdeckungsgebiete zu erfüllen. Der Spotlight Modus fokussiert sich auf einen kleineren Bereich und behält den Fokus für längere Zeit auf demselben Ziel, was für eine hohe räumliche Auflösung für den fokussierten Bereich sorgt. Beim Stripmap Modus scannt das RADAR kontinuierlich entlang der Flugbahn des Satelliten einen breiten Bereich ab, was für eine gleichmäßige Auflösung über ein größeres

Gebiet sorgt. Beim ScanSAR Modus wird die Antenne abwechselnd auf verschiedene Bereiche gerichtet, was dafür sorgt, dass eine sehr breite Abdeckung erreicht wird, allerdings ist die räumliche Auflösung gering [8].

Die Orbitphase beschreibt die Satellitenbewegung entlang ihrer Umlaufbahn. Bei dem Ascending Orbit bewegt sich der Satellit von Süden nach Norden und bei dem Descending Orbit dementsprechend von Norden nach Süden [8].

2.3 Sentinel 1 Mission

Die Sentinel 1 Mission ist ein zentraler Bestandteil des Copernicus-Programms der European Space Agency (ESA) und hat zum Ziel, kontinuierliche und zuverlässige Radardaten für vielfältige Anwendungen in der Erdbeobachtung bereitzustellen. Zu den Hauptanwendungsbereichen gehören die Überwachung von Landbewegungen, die Meeresbeobachtung, das Katastrophenmanagement und die Klimaforschung. Die Mission umfasst eine Konstellation von Satelliten, beginnend mit Sentinel 1A, der am 3. April 2014 erfolgreich gestartet wurde. Ihm folgte Sentinel 1B am 25. April 2016, der jedoch seit dem 23. Dezember 2021 aufgrund technischer Probleme außer Betrieb ist. Um die Kontinuität der Datenversorgung sicherzustellen, ist der Start von Sentinel 1C zu Beginn 2024 geplant [12]. Die Satelliten bewegen sich auf einer sonnensynchronen, polar umlaufenden Umlaufbahn in etwa 693 Kilometern Höhe und sind mit einem C-Band SAR ausgestattet [2.1]. Dieses Instrument ermöglicht es, unabhängig von Wetterbedingungen und Tageszeit hochauflösende Bilder der Erdoberfläche zu erfassen [12]. Die von Sentinel 1 generierten Daten sind frei zugänglich und können über das Copernicus Data Space heruntergeladen werden. Das SAR-Instrument von Sentinel 1 bietet verschiedene Betriebsmodi, um unterschiedlichen Beobachtungsanforderungen gerecht zu werden [2.2] [13].

Parameter	Interferometric Wide-swath mode (IW)	Wave Mode (WV)	Strip Map mode (SM)	Extra Wide-swath mode (EW)
Polarisation	Dual (HH+HV, VV+VH)	Single (HH, VH)	Dual (HH+HV, VV+VH)	Dual (HH+HV, VV+VH)
Access (incidence angles)	31° - 46°	23° - 37° (mid-incidence angle)	20° - 47°	20° - 47°
Azimuth resolution	20 m	5 m	5 m	40 m
Ground range resolution	5 m	5 m	5 m	20 m
Azimuth and range looks	Single	Single	Single	Single
Swath	250 km	Vignette 20 x 20 km	80 km	410 km
Maximum noise-equivalent sigma zero (NESZ)	-22 dB	-22 dB	-22 dB	-22 dB

Tabelle 2.2: Vergleich der Sentinel 1-SAR Modi [14]

Durch ihre Fähigkeit, unter allen Wetterbedingungen und zu jeder Tageszeit hochauflösende Radarbilder zu liefern, spielt die Sentinel 1 Mission eine entscheidende Rolle in der modernen Erdbeobachtung. Sie ermöglicht es, globale Herausforderungen besser zu verstehen und effektive Maßnahmen im Umweltmonitoring und Katastrophenmanagement zu ergreifen [13]. Die Daten der Sentinel 1 Mission werden in verschiedenen Verarbeitungsstufen aufbereitet und als unterschiedliche Produkte herausgegeben [12].

2.3.1 Level 0

Als Level 0 werden die Rohdaten bezeichnet. Sie enthalten keine Bildinformationen, sondern nur das unformatierte Signal des SAR-Sensors. Diese Daten werden hauptsächlich für interne Zwecke verwendet und zur Archivierung benutzt [15].

2.3.2 Level 1

Das ist die erste Verarbeitungsstufe, bei der die Rohdaten in georeferenzierte SAR-Bilder umgewandelt werden. Hier gibt es zwei verschiedene Produkte. Das Level 1 Single Look Complex (SLC), welches die vollständige Amplitude und Phase des Signals beibehält und das Level 1 Ground Range Detected (GRD), welches radiometrisch und geometrisch korrigiert ist [15].

2.3.3 Level 2

Das Level 2 Ocean (OCN) basiert auf beiden Level 1 Produkten wurde allerdings speziell für ozeanografische Anwendungen verarbeitet. Mit diesem Produkt lassen sich Meeresoberflächenbedingungen überwachen, da hier aus den Radardaten relevante ozeanografische Informationen extrahiert werden [15].

2.3.4 Level 3

Bei dem Level 3 Monthly Mosaics wird auf Basis von den Level 1 GRD Daten ein monatliches Gesamtmosaik gebildet, in dem die gewichtete Summe von den geländekorrigierten Rückstreuungsdaten berechnet wird. Pro Monat werden zwei verschiedene Mosaike produziert. Das IW-Mosaik ist besonders sinnvoll für Anwendungen mit größerer Abdeckung und das DH-Mosaik für Anwendungen mit detaillierteren Bereichen [15].

2.4 Forschungsbereich

Die Forschungsbereich der Bachelorarbeit erstreckt sich vom Weddellmeer am Larson Shelfeis vorbei bis zu den südlichen Orkneyinseln [2.1] [16].




Abbildung 2.1: Studienregion

2.5 Google Earth Engine

Die Google Earth Engine (GEE) ist eine cloudbasierte Computing-Plattform, die die Infrastruktur von Google nutzt, um den Zugang zu Geodaten und deren Verarbeitung zu erleichtern [17]. Um die Plattform zu nutzen ist ein Google Konto erforderlich und für Bildungs bzw. Forschungszwecke ist die Nutzung kostenlos. Die Ziele der GEE sind: eine dynamische Plattform zu bieten, die die Entwicklung von Algorithmen mit großen Datenmengen erleichtert, die Forschung durch freien Zugang zu fördern und Teil des Fortschritts und der Lösungen für die globale Nachfrage und das Management von Big Data zu sein [18, 19].

Die GEE verfügt über einen umfangreichen Katalog, der eine Vielzahl von Geodaten umfasst, darunter Daten von Landsat-, Sentinel- und MODIS Satelliten. Ein zentraler Bestandteil der GEE ist der integrierte Code-Editor, der eine vollständige Entwicklungsumgebung bereitstellt und die Nutzung von JavaScript und Python zur Programmierung und Automatisierung von Geodatenanalysen ermöglicht. Die Plattform unterstützt eine Vielzahl von APIs und ermöglicht so den direkten Zugriff auf Daten und Algorithmen, die in der GEE verfügbar sind [18].

Darüber hinaus bietet die Plattform eine Vielzahl von Algorithmen für maschinelles Lernen, Bildverarbeitung, Zeitreihenanalyse und Datenreduktion, was sie zu einem unverzichtbaren Werkzeug für die Bearbeitung und Analyse großer geowissenschaftlicher Datensätze macht [19].

2.6 QGIS

QGIS (Quantum Geographic Information System) ist ein Open-Source geografisches Informationssystem (GIS), das es Nutzern ermöglicht, räumliche Daten zu erfassen, zu bearbeiten, zu analysieren und zu visualisieren. Die Software bietet eine leistungsstarke und benutzerfreundliche Plattform für GIS-Anwendungen und wird weltweit in verschiedenen Bereichen wie in der Stadtplanung eingesetzt. Durch die offene Architektur und die große Entwicklergemeinschaft steht QGIS kostenlos zur Verfügung und kann an spezifische Bedürfnisse angepasst werden. Genutzt wurde die QGIS Desktop Version 3.36.3 [20].

QGIS unterstützt eine Vielzahl von Vektor- und Rasterdatenformaten, darunter gängige Formate wie Shapefiles, GeoTIFFs sowie Datenbanken wie PostgreSQL in Verbindung mit PostGIS. Dank der Unterstützung von Webdiensten wie WMS (Web Map Service) und WFS (Web Feature Service) ist es möglich, auf externe Geodatenquellen zuzugreifen und diese in Echtzeit zu visualisieren [21].

Die Software bietet eine breite Palette von Analysewerkzeugen, mit denen sowohl einfache als auch komplexe GIS-Operationen durchgeführt werden können. Ein herausragendes Merkmal von QGIS ist seine Erweiterbarkeit durch Plug-ins, die zusätzliche Funktionen wie maschinelles Lernen oder Fernerkundung bereitstellen [21]. Zudem ermöglicht die PyQGIS-Bibliothek die Programmierung und Automatisierung von Prozessen über Python, was es zu einem flexiblen Werkzeug auch für fortgeschrittene Nutzer macht [22].

2.7 Orfeo Toolbox

Die Orfeo ToolBox (OTB) ist eine leistungsstarke, Open-Source Software für die Verarbeitung von Fernerkundungsdaten, die von der geowissenschaftlichen Gemeinschaft entwickelt wurde. Sie wurde ursprünglich von der französischen Raumfahrtagentur CNES ins Leben gerufen, um den speziellen Anforderungen der Verarbeitung hochauflösender Satellitenbilder gerecht zu werden. Inzwischen hat sich OTB zu einer vielseitigen Plattform entwickelt, die eine breite Palette von Anwendungen für die Bildverarbeitung, Klassifizierung und Analyse von Fernerkundungsdaten bietet. Genutzt wurde die OTB Version 9.0.0 [23, 24].

2 Grundlagen

OTB unterstützt sowohl die Verarbeitung von optischen, als auch radar-basierten Fernerkundungsdaten und bietet Algorithmen für die Orthorektifizierung, Pan-Sharpening, Segmentierung, Klassifizierung und mehr. Zu den unterstützten Sensoren gehören unter anderem die Sentinel- und Landsat-Satelliten, was die Plattform besonders relevant für die Erdbeobachtung und Umweltüberwachung macht. Dank ihrer modularen Architektur und der Integration in andere GIS-Software wie QGIS können Nutzer OTB flexibel in ihren Workflows einsetzen, sei es über die Kommandozeile, Python-Skripte oder über die grafische Benutzeroberfläche [24].

Die Software ist auf eine breite Anwenderschaft ausgelegt und wird kontinuierlich weiterentwickelt, um den neuesten wissenschaftlichen Fortschritten in der Bildverarbeitung gerecht zu werden [23].

3 Methodik

Im Methodikteil werden die eingesetzten Funktionen und Algorithmen erläutert.

3.1 Sentinel 1 Preprocessing Workflow

Entstanden aus zwei verschiedenen Workflows.




Abbildung 3.1: Sentinel-1 Preprocessing Workflow [25]

3.1.1 Apply Orbit File

Durch das hinzufügen von präzisen Orbitdaten werden die Positions- und Geschwindigkeitsinformationen des Satelliten aktualisiert. Dies erhöht die Genauigkeit der Geolokalisierung der SAR-Daten [25].

3.1.2 Thermal Noise Removal

Das Thermal Noise Removal entfernt unerwünschtes thermisches Rauschen, welches durch Störungen zwischen den verschiedenen Sub-Swaths entstehen kann. Häufig sind SAR-Bilder betroffen, bei denen die Rückstreuung gering ist [25].

3.1.3 Border Noise Removal

Hierbei werden die Artefakte an den Bildrändern entfernt, welche durch die Kompressionsverfahren der SAR-Sensoren verursacht werden [25].

3.1.4 Calibration

Bei der Calibration werden die Rohdaten in radiometrisch kalibrierte Rückstreuwerte konvertiert, sodass die Pixelwerte die tatsächliche Rückstreuung der Erdoberfläche repräsentieren [25].

3.1.5 Speckle Filtering

Durch das Anwenden vom Speckle Filtering wird das Rauschen der SAR-Daten reduziert, was zu glatteren und klareren Bildern führt [25].

3.1.6 Range Doppler Terrain Correction

Diese Korrektur gleicht geometrische Verzerrungen aufgrund der Topografie und des Blickwinkels des Satelliten aus [25].

3.1.7 Conversion to dB

Abschließend werden die Daten in Dezibel (dB) umgewandelt. Dieser Schritt hilft dabei die Daten besser zu visualisieren und zu analysieren [25].

3.2 Large Scale Mean Shift

Der Large Scale Mean Shift (LSMS) ist ein Segmentierungsalgorithmus, welcher große Bilder in kleinere Segmente unterteilt, damit diese effizient verarbeitet werden können. Der LSMS ist Teil der OTB und wird für objektbasierte Bildanalysen verwendet. Der Workflow besteht aus einer Verkettung von vier Teilschritten, welche in den folgenden Abschnitten detailliert erklärt werden [\[23\]](#).

3.2.1 Smoothing

Der erste von den vier Teilschritten ist das Smoothing. Hierbei wird ein Mean-Shift-Smoothing Algorithmus angewandt, welcher dafür sorgt, dass das Bildrauschen reduziert wird. Durch die Verwendung eines räumlichen Radius (ranger) und eines spektralen Radius (spatialr) werden Pixel mit ähnlichen räumlichen und spektralen Eigenschaften gruppiert, was die Identifikation von klar abgegrenzten Regionen erleichtert [\[23\]](#), [\[26\]](#).

3.2.2 Segmentation

Nach dem Smoothing führt der LSMS-Algorithmus die Segmentation auf Grundlage der vorher verarbeiteten Bilder durch. Die Segmentation fasst benachbarte Pixel zusammen, wenn der Abstand unter den vorher eingestellten Parametern ranger und optional auch spatialr liegt. Zusätzlich dazu lässt sich die Größe der Kacheln bei der Segmentation festlegen (tilesex und tilesey). Segmente die eine definierte Mindestgröße (minsize) nicht erreichen, werden herausgefiltert und entsprechend gekennzeichnet [\[23\]](#), [\[26\]](#).

3.2.3 Small Region Merging

Nach der Segmentation wird der Small Region Merging Algorithmus ausgeführt. Hierbei wird überprüft, ob kleinere Segmente mit benachbarten größeren Segmenten zusammengeführt werden können. Dieser Schritt verhindert eine Übersegmentierung und stellt sicher, dass die daraus entstandenen Segmente die tatsächlichen Objekte im Bild besser repräsentieren [\[23\]](#), [\[26\]](#).

3.2.4 Vectorization

Im letzten Schritt wird das segmentierte Bild vektorisiert. Dabei wird das Rasterbild in eine Vektordatei umgewandelt. Die Vektordatei enthält ein Polygon pro Segment und jedes dieser Polygone enthält zusätzliche Attribute, wie die Bezeichnung des ursprünglichen Segments, die Größe des Segments in Pixeln, etc. [\[23\]](#), [\[26\]](#).

3.3 Machine Learning

Machine Learning (ML) ist ein Teilgebiet der künstlichen Intelligenz, das sich mit der Entwicklung von Algorithmen und Modellen beschäftigt. ML ermöglicht es, aus Daten zu lernen und Muster zu erkennen, ohne explizit programmiert zu sein. Durch diese Fähigkeit können Maschinen aus Erfahrungen lernen und ihre Leistung im Laufe der Zeit verbessern [27].

Es gibt verschiedene Ansätze im ML, darunter überwachtes Lernen, unüberwachtes Lernen und bestärkendes Lernen. Überwachtes Lernen nutzt gelabelte Datensätze, um Vorhersagen zu treffen oder Klassifizierungen vorzunehmen. Unüberwachtes Lernen sucht nach verborgenen Mustern oder Strukturen in unbeschrifteten Daten. Bestärkendes Lernen basiert auf dem Prinzip von Belohnungen und Bestrafungen, um optimale Handlungsstrategien zu erlernen [28].

Die Anwendungen des ML sind vielfältig. Durch die effiziente Verarbeitung großer Datenmengen treibt maschinelles Lernen Innovationen in vielen Branchen voran und verändert die Art und Weise, wie Technologie genutzt wird [27].

3.3.1 Random Forest

Der Random-Forest-Algorithmus (RF) ist ein überwachtes Lernverfahren, das sowohl für Klassifikations- als auch für Regressionsaufgaben eingesetzt wird. Er kombiniert die Vorhersagen mehrerer Entscheidungsbäume, um die Genauigkeit des Modells zu erhöhen. Durch die Aggregation der Ergebnisse vieler Bäume wird die Varianz reduziert und das Risiko von Overfitting minimiert [29].

Die Funktionsweise des RF basiert auf zwei Hauptprinzipien: dem Bootstrap-Aggregating und der zufälligen Merkmalsauswahl. Bei jedem Entscheidungsbaum wird eine Stichprobe mit Zurücklegen aus dem ursprünglichen Datensatz gezogen, und bei jeder Aufteilung wird eine zufällige Untermenge von Merkmalen betrachtet. Dies führt zu einer hohen Diversität unter den Bäumen und verbessert die Gesamtleistung des Modells [30].

Der RF ist besonders effektiv bei großen Datensätzen mit vielen Variablen und kann auch mit fehlenden Werten umgehen. Er bietet zudem interne Methoden zur Gewichtung von Merkmalen, was für die Interpretation des Modells und die Feature Selection hilfreich ist [31].

Trotz der vielen Vorteile hat der RF auch einige Nachteile. Besonders bei extrem großen Datensätzen ist das Training und die Anwendung vieler Entscheidungsbäume zeitaufwändig und ressourcenintensiv. Aufgrund der vielen Entscheidungsbäume ist der RF auch weniger interpretierbar als ein einzelner Entscheidungsbaum [30].

3.4 Trainingsdaten

Trainingsdaten sind ein wichtiger Bestandteil von Machine Learning Algorithmen. Sie bestehen aus Beispielen, die der Algorithmus nutzt, um zu lernen. Ziel ist es, Muster und Zusammenhänge in den Daten zu finden. Durch wiederholtes Durchlaufen der Trainingsdaten lernt der Algorithmus Vorhersagen zu treffen. Damit der Algorithmus gut funktioniert, müssen die Trainingsdaten möglichst vielfältig und ein breites Spektrum an Beispielen abdecken. Gerade bei neuen und unbekannten Daten müssen viele Beispiele vorliegen mit denen der Algorithmus trainieren kann, damit er auch in einem schwierigen Fall gute Vorhersagen treffen kann. Falls das nicht der Fall ist kann der Algorithmus nicht wie gewünscht arbeiten und erfüllt nicht seinen Zweck. Bei fehlerhaften oder unvollständigen Trainingsdaten wird der Algorithmus falsch trainiert und das führt zu falschen Ergebnissen, deshalb ist es wichtig, qualitativ hochwertige Trainingsdaten zu verwenden [32].

3.5 Validierungsmethoden

Um die Leistung des erstellten ML-Modells zu bewerten, gibt es Validierungsmethoden.

3.5.1 Accuracy

Die Accuracy teilt die Anzahl der korrekten Vorhersagen (True Positives und True Negatives) durch die Gesamtanzahl der Vorhersagen (True Positives, True Negatives, False Positives und False Negatives). Diese Validierungsmethode ist einfach zu verstehen und leicht in ihrer Berechnung.

$$\text{Accuracy} = \frac{\text{TP} + \text{TN}}{\text{TP} + \text{TN} + \text{FP} + \text{FN}} \quad [33] \quad (3.1)$$

4 Implementierung

Im Implementierungsteil werden die zuvor erklärten Methoden umgesetzt.

4.1 Automation Datenbeschaffung GEE Skript

In dem Google Earth Engine Code Editor wird das erstellte Skript ausgeführt. Um die erwünschten Sentinel 1 SAR-Daten für den vorher festgelegten Forschungsbereich zu erhalten wird eine Bounding Box (BBOX) erstellt. Für diese BBOX werden dann die Sentinel 1-SAR Daten gesucht und nach dem HH Band gefiltert. Daher, dass das Gebiet so groß ist müssen die Sentinel 1-SAR Daten miteinander verschmelzt werden. Hierfür werden die Bilder als Mosaik zusammengefügt. Nachdem die Zielprojektion auf die Polarprojektion (EPSG:3031) angepasst wurde werden einzelne Monatslayer heruntergeladen. In der folgenden Abbildung [4.1](#) ist exemplarisch der Layer von Januar 2022 dargestellt.



Abbildung 4.1: GEE Ergebnis für Januar 2022




Abbildung 4.2: Darstellung von den zwei vorher beschriebenen Verschmelzoptionen

Das Verschmelzen der Bilder durch ein Mosaik [4.2\(a\)](#) sorgt für eine höhere Wahrscheinlichkeit, dass der Eisberg in einem Stück visualisiert werden kann. Bei der Verschmelzung der Bilder durch die Medianberechnung [4.2\(b\)](#) kann es zu einer Zerstückelung des Eisbergs kommen, weshalb diese keine Anwendung gefunden hat.

4.2 Vorauswahl Bilder

Nach Download der Layer erhält man 30 .tif Dateien (von Januar 2022 bis Juni 2024), bei diesen Bildern gibt es allerdings insgesamt 7 Bilder bei denen der Eisberg fehlerhaft abgebildet wird, obwohl das Verschmelzen durch ein Mosaik angewendet wurde. Das passiert, da der Eisberg zu groß ist um von dem Satelliten zuverlässig auf einem Bild erfasst zu werden. Die fehlerhaften Layer sind 2022 der Februar, Mai und August. 2023 sind es die Layer im Juni, September und Dezember und 2024 ist es nur der Layer aus dem Januar. In der Grafik [4.3\(b\)](#) der Eisberg aus dem Layer Februar 2022 dargestellt. Hier wird das Problem mit der Verzerrung des Eisbergs deutlich.




Abbildung 4.3: Vorauswahl der brauchbaren Eisberge

4.3 Preprocessing Sentinel 1

Die Sentinel 1 SAR-Daten wurden als GRD Daten heruntergeladen, dabei werden die Sentinel 1 Bilder von dem Sentinel Hub schon vorverarbeitet [34]. Zudem ist der Eisberg gut zu erkennen und es wurden direkt in QGIS Rasterbilder ausgeschnitten, wo der Eisberg zu sehen ist. Dies musste erfolgen, da sonst das Tool LSMS zu lange gedauert hätte. Es wurde lediglich ein Despeckle Algorithmus ausgeführt. Als Despeckle Algorithmus wurde der LEE Algorithmus ausgewählt Radius 1 und Number of Looks auch 1 [35]. Der Algorithmus sorgt dafür, dass der Eisberg und dessen Kanten leichter für den LSMS Algorithmus zu erkennen sind.

4.4 Large Scale Mean Shift

Fortführend wurde der Large Scale Mean Shift Algorithmus (LSMS) ausgeführt. Dabei sind die verwendeten Parameter:

1. Spatial Radius 50: Standardmäßig ist dieser auf 5 eingestellt, ein höherer Wert sorgt für ein besseres Smoothing Ergebnis, führt aber auch zu einer längeren Rechenzeit [36].
2. Range Radius 5: Der Standardwert liegt hier bei 15.00. Der Range Radius gibt an, wie viele benachbarte Pixel für die Berechnung herangezogen werden. Ein hoher Wert führt zu einer besseren Rauschunterdrückung, allerdings werden hier die Kanten nicht gut beibehalten [36].

4 Implementierung

3. Minimum Segment Size 500: Der Standardwert liegt hier bei 50. Dieser Parameter fasst umliegende Segmente zusammen, sodass die kleinste Segmentgröße mindestens 500 Pixel groß sein muss. Hierfür werden die Segmente mit dem Segment zusammengeführt, das die ähnlichste spektrale Signatur zuweist [\[36\]](#).




Abbildung 4.4: LSMS für den Januar 2022

4.5 Trainingsdatenbeschaffung

Zunächst wurde ein neuer Layer für die Trainingsdatenbeschaffung erstellt. Dieser Layer wurde so eingestellt, dass er die Projektion EPSG: 3031 hat und Polygone abspeichert, zudem wurde ein neues Feld namens `class_id` angelegt. Hier werden die Werte als Integer abgespeichert. Da der Eisberg vom Wasser getrennt werden sollte, gibt es zwei Klassen die unterschieden werden:

1. Eis mit der id 1 und
2. Wasser mit der id 2

Insgesamt wurden für jede Klasse 10 Trainingspolygone erstellt.

4.6 Klassifikation

Für die Klassifikation werden zunächst die Zonal Statistics des eingeladenen Bildes vom Eisberg [4.3\(a\)](#) mit dem LSMS Bild vom Eisberg [4.4](#) erstellt. Danach werden die erstellen Zonal Statistics mit dem Werkzeug Join Attributes by Location mit den Trainingsdaten verbunden. Mit dem Werkzeug TrainVectorClassifier wird ein .model erstellt, dass mit dem RF Algorithmus die Trainingsdaten mit den Zonal Statistics trainiert. Die Accuracy beträgt während dieses Schritts 1. Mit dem VectorClassifier Werkzeug wird dann mit Eingabe von den Zonal Statistics und dem eben erstellen Model eine Prediction ausgegeben. Diese Prediction kann über die Einstellungen des Layers und dann bei Symbology, Categorized, Value predicted, Classify angezeigt werden. Als letzten Schritt wird dann mit dem Werkzeug Dissolve der erkannte Eisberg ausgeschnitten [37](#). In der Abbildung [4.5](#) wird das Endergebnis der Klassifikation für den Januar 2022 angezeigt.



Abbildung 4.5: Eisberg Modell von Januar 2022

4.7 Berechnungen

4.7.1 Flächeninhalt

Um die Fläche in Quadratkilometern (km²) zu berechnen muss jeder Layer einzeln ausgewählt werden. Die Attributtabelle des ausgewählten Layers wird öffnet und in der Menüleiste den Feldrechner ausgewählt. Jetzt muss für die Berechnung des Flächeninhalts ein neues Feld erstellt werden. Als Feldnamen fläche km2 eingeben und den Feldtyp auf Dezimalzahl umstellen. Im Ausdrucksfeld muss nun die Formel:

$$\text{Flächeninhalt} = \$area \div 1.000.000 \quad (4.1)$$

eingetragen werden. Mit dieser Formel [4.1](#) wird der Flächeninhalt von Quadratmetern in Quadratkilometern umgerechnet. Nun noch die Formel bestätigen und dann wird das neue Feld in der Attributtabelle angezeigt.

4.7.2 Schmelzrate

Die Schmelzrate wird von dem Flächeninhalt hergeleitet.

$$\text{Schmelzrate} = \frac{\text{aktueller Flächeninhalt} - \text{vorheriger Flächeninhalt}}{\text{vorheriger Flächeninhalt}} \times 100 \quad (4.2)$$

Mit dieser Formel [4.2](#) wird immer der prozentuale Wachstum bzw. die Schrumpfung des aktuellen Eisbergs zu dessen Vormonat bestimmt.

4.7.3 Zentrum

Für die Zentrumsberechnung muss in der Werkzeugliste nach Centroids gesucht werden. Nach Doppelklick auf das Werkzeug wählt man den Polygonlayer aus, für den das Zentrum bestimmt werden soll und startet die Berechnung. Für den ausgewählten Layer wird jetzt mit einem Punkt das Zentrum angezeigt.

4.7.4 Zurückgelegte Distanz

Die zurückgelegte Distanz zwischen den Intervallen wird mit der Distanzmatrix berechnet, in dem der Start- und Zielpunkt ausgewählt werden. Hierfür eignen sich die vorher berechneten Zentren der Eisberge. Das Distanzmatrixwerkzeug wird mit der Werkzeugliste aufgerufen. Nach einstellen des Start- und Zielpunkts wird dann ein neuer Layer hinzugefügt. In der Attributtabelle des neuen Layers steht dann die Distanz zwischen beiden Punkten in Metern.

5 Ergebnisse & Analyse

Die Ergebnisse der Klassifikation und der Berechnungen werden hier dargestellt.

5.1 Verfolgungskarte




Abbildung 5.1: Verfolgungskarte des Eisbergs A23a von Januar 2022 bis Juni 2024

Die vorliegende Karte [5.1](#) zeigt die Nachverfolgung des Eisbergs A23a von Januar 2022 bis Juni 2024. Der Kartenausschnitt zeigt die Region um das Weddellmeer bis hin zu den südlichen Orkneyinseln.

5 Ergebnisse & Analyse

Ziel der Karte ist die Route des Eisbergs A23a darzustellen, dabei wird für jeden Monat innerhalb des gegebenen Zeitintervalls ein Eisberg angezeigt. Für eine bessere graphische Einordnung sind die Eisberge abwechselnd orange und grün dargestellt. Zu jedem Eisberg ist der jeweilige Monat mit einem Pfeil zugeordnet, zudem werden die Zentren der Eisberge angezeigt. Die Route des Eisbergs ist mit einer feinen schwarzen Linie dargestellt, dabei ist der Eisberg zu Beginn (Januar 2022) im Weddellmeer und zum Schluss (Juni 2024) nördlich der südlichen Orkneyinseln.

In der unteren rechten Ecke der Karte befindet sich eine Maßstabsleiste, die die Entfernungen in 250km Schritten anzeigt. Dies hilft, die zurückgelegte Strecke des Eisbergs zu veranschaulichen. Oben links in der Ecke ist der Nordpfeil und oben rechts in der Ecke ist eine kleine Übersichtskarte von dem dargestellten Gebiet.

5.2 Tabellen

5.2.1 Flächeninhalt




Abbildung 5.2: Flächeninhalt

Die Grafik [5.2](#) zeigt die Entwicklung des Flächeninhalts der monatlich erfassten Eisberge in Quadratkilometern an. Dabei zeigt die Y-Achse die Quadratkilometer von einer Skala von 3500 bis 4900km² und die X-Achse die monatlichen Zeitabstände an.

In den meisten Monaten schwankt der Flächeninhalt nur geringfügig und bewegt sich im Bereich zwischen 3950 km² und 4200 km². Es gibt jedoch mehrere Auffälligkeiten. Während von Januar 2022 bis zum Februar 2024 der Flächeninhalt schwankt schießt der Wert für den März 2024 nach oben. Dies ist zurückzuführen auf das LSMS Algorithmus Ergebnis für diesen Monat. Der Algorithmus konnte den Eisberg nicht so zuverlässig erkennen, wie zu den anderen Zeitpunkten und somit erreicht der Wert einen Höhepunkt mit einer Fläche von 4961,75km². Abgesehen davon ist zu erkennen, dass ab dem Februar 2024 bis zum Ende der Datenerfassung, dem Juni 2024, der Flächeninhalt deutlich schneller sinkt als von der Zeitspanne von Januar 2022 bis zum Februar 2024. Dies ist darauf zurückzuführen, dass der Eisberg sich zu diesem Zeitpunkt in erheblich wärmeren Meerestemperaturen aufhält als zu Beginn.

5.2.2 Schmelzrate




Abbildung 5.3: Schmelzrate

Die Grafik [5.3](#) zeigt die Entwicklung der Schmelzrate der monatlich erfassten Eisberge in Prozent zu deren Vormonat an. Dabei zeigt die Y-Achse die Schmelzrate in % von einer Skala von -10 bis 5 Prozent und die X-Achse die monatlichen Zeitabstände an. Ein negativer Wert steht für eine Abnahme der Eisfläche, während ein positiver Wert auf eine Zunahme des Eises hindeutet.

Diese Grafik [5.3](#) unterstreicht das Ergebnis aus [5.2](#), da die Schmelzraten von Januar 2022 bis Februar 2024 sich mehr oder weniger ausgleichen. Der

5 Ergebnisse & Analyse

Höhepunkt liegt wieder im März 2024. Hier beträgt die Zunahme des Eises im Vergleich zum Vormonat 23,98%. Im April und Mai 2024 hingegen schmilzt 22,22% beziehungsweise 6,23% des Eises. Diese beiden Werte sind die höchsten Schmelzraten, wobei die hohe Schmelzrate von 22,22% nicht repräsentativ ist, sondern aufgrund des fehlerhaften LSMS-Algorithmus entstanden ist.

5.2.3 Zurückgelegte Distanz




Abbildung 5.4: Zurückgelegte Distanz

Die letzte Grafik [5.4](#) zeigt die zurückgelegte Distanz der monatlich erfassten Eisberge in Kilometern zu deren Vormonat an. Dabei zeigt die Y-Achse die Strecke in Kilometern von einer Skala von 0 bis 450 Kilometern und die X-Achse die monatlichen Zeitabstände an.

Hervorzuheben ist, dass die zurückgelegte Strecke von Januar 2022 bis Mai 2023 recht gering ist, vor allem wenn bedacht wird, dass in diesem Zeitraum der Februar, Mai und August 2022 fehlen. Die Werte von Juli 2023, Oktober 2023 und Februar 2024 entsprechen nicht der tatsächlichen Distanz, da ein Monat (Juli 2023 und Oktober 2023) respektive zwei Monate (Februar 2024) fehlen. Nichtsdestotrotz erreicht die zurückgelegte Distanz im März 2024 einen Wert von 395,78km, was darauf zurückzuführen ist, dass zwischen dem Februar und März 2024 die Meereswasserströmung extrem gewesen sein muss. Auffällig ist auch, dass der Eisberg im April bis zum Juni 2024 wenig Strecke zurückgelegt hat, obwohl der Eisberg mittlerweile ungeschützt und in wärmeren Gebieten verweilt.

6 Diskussion

In dieser Arbeit wurden Sentinel 1-SAR Daten genutzt, um Eisberge zu beobachten und zu kartieren. Der große Vorteil der Sentinel 1 SAR Daten ist, dass sie unabhängig von den äußeren Einflüssen gute Daten liefern, da sie mit einem RADAR ausgestattet sind, welches nicht von Wolken beeinträchtigt wird. Die Nutzung von RADAR gestützten Daten ist in Regionen mit vielen Wolken besonders sinnvoll. Mit der Google Earth Engine kann man die Sentinel 1-SAR Daten leicht suchen, filtern und verarbeiten, allerdings gibt es eine Einschränkung in der maximalen Pixelanzahl pro Layer, deshalb muss bei der Verfolgung eines Eisberges die Bounding Box aufwändig angepasst werden. Zudem ist der Bereich vom Eisberg so groß, sodass es notwendig ist einen Mosaiklayer zu erstellen. In einigen Fällen kann der Eisberg dadurch verzerrt dargestellt werden, was dazu führt das der komplette Layer für den Monat fehlerhaft ist. Wenn der Eisberg jedoch mittig auf einem Teilstück eines Mosaiks liegt, kann der Layer problemlos genutzt werden und der Layer kann wie in der Arbeit beschrieben zu guten Ergebnissen beitragen. Insgesamt hängt die Qualität der Ergebnisse zu stark davon ab, wie der Satellit das Gebiet erfasst hat. Zudem kann der Nutzer nicht aktiv beeinflussen, wann ein Eisberg auf einem Layer gut angezeigt werden kann und wann nicht, da der Satellit nicht gesteuert werden kann.

In Bezug auf die automatische Visualisierung von Eisbergen in QGIS bietet der Model Builder grundsätzlich die Möglichkeit Arbeitsprozesse zu automatisieren. In der Praxis gibt es jedoch Einschränkungen in der Nutzung des Model Builders, insbesondere wenn der LargeScaleMeanShift Algorithmus verwendet wird. Das Problem besteht darin, dass der Model Builder es dem Nutzer nicht erlaubt, ganze Ordner mit Bilddaten als Eingabequelle festzulegen. Stattdessen muss jeder Layer manuell ausgewählt und verarbeitet werden. Das verändern der Eingabeparameter ist nicht der Sinn einer Automation. Da dies aktuell nicht anders umgesetzt werden kann, wurde der QGIS eigene Model Builder nicht verwendet. Stattdessen wurden die Schritte manuell ausgeführt.

Durch die Berechnung des Flächeninhalts, der Schmelzrate, des Zentrums und der Geschwindigkeit eines Eisbergs können wertvolle Erkenntnisse gewonnen werden. Durch die entstandenen Diagramme werden die Veränderungen des Eisbergs in dem Zeitintervall von Januar 2022 bis Juni 2024 gut visualisiert.

7 Abschluss

7.1 Fazit

In dieser Arbeit wurde gezeigt, dass Sentinel 1-SAR Daten eine zuverlässige Methode zur Beobachtung und Kartierung von Eisbergen darstellen, da sie unabhängig von Wetterbedingungen brauchbare Daten liefern. Die Nutzung von der Google Earth Engine erleichtert die Datenverarbeitung, jedoch können die Eisberge aufgrund der Mosaikbildung verzerrt angezeigt werden. Die Limitierung der maximalen Pixelobergrenze in der GEE ist ein weiterer Störfaktor. QGIS bietet Ansätze zur Automatisierung, stößt aber aufgrund technischer Einschränkungen im Bezug zum Model Builder an seine Grenzen. Die Analyse der Flächenveränderung, Schmelzrate und zurückgelegten Distanz ermöglicht wichtige Einblicke in das Verhalten von Eisbergen, welche im Meer herumtreiben. Trotz vieler Automatisierungsmöglichkeiten ist die vollständige Automatisierung abhängig von vielen verschiedenen Faktoren, welche erst noch miteinander verknüpft werden müssen um zu funktionieren.

7.2 Ausblick

Die Datenerfassung mit der Google Earth Engine ist grundsätzlich sehr einfach, aber noch fehleranfällig. Zudem ist es nicht möglich einen größeren Bereich herunterzuladen, da die GEE nur eine maximale Pixelanzahl pro Layer erlaubt. Wenn diese Einschränkungen in Zukunft behoben werden ist eine vollständige Verfolgung eines Eisbergs ohne unbrauchbare Layer, bei denen der Eisberg verzerrt ist, möglich. Der QGIS Model Builder hat sich als wenig sinnvoll erwiesen. In zukünftigen Arbeiten könnte es besser sein, mit PyQGIS zu arbeiten, um einen automatisierten Prozess zu erstellen. Dadurch ließen sich automatisierte Analysen besser umsetzen und die Datenverarbeitung deutlich verbessern. Zudem könnten weitere Daten mit in die Analyse einbezogen werden, wie beispielsweise die Wassertemperatur oder die Wasserströmung. Hiermit könnte ein weitaus aufschlussreicheres Endergebnis erstellt werden.

8 Anhang

Das Skript für die Google Earth Engine und das QGIS-Dokument sind in GitHub <https://github.com/tlehman1> unter dem Repository <https://github.com/tlehman1/Bachelorarbeit> wiederzufinden.

Abbildungsverzeichnis

2.1 Studienregion	8
3.1 Sentinel-1 Preprocessing Workflow [25]	11
4.1 GEE Ergebnis für Januar 2022	17
4.2 Darstellung von den zwei vorher beschriebenen Verschmelzop- tionen	18
4.3 Vorauswahl der brauchbaren Eisberge	19
4.4 LSMS für den Januar 2022	20
4.5 Eisberg Modell von Januar 2022	21
5.1 Verfolgungskarte des Eisbergs A23a von Januar 2022 bis Juni 2024	23
5.2 Flächeninhalt	24
5.3 Schmelzrate	25
5.4 Zurückgelegte Distanz	26

Tabellenverzeichnis

2.1	Bänder der SAR Systeme mit Wellenlänge und Frequenz [8]	. .	4
2.2	Vergleich der Sentinel 1-SAR Modi [14]		6

Literaturverzeichnis

- [1] SANDERSON, Grant: *Annulus Calculus Revisited*. YouTube-Video. https://www.youtube.com/watch?v=WYPW_mWPF1E. Version: 2023. – Zugriff: 30.09.2024
- [2] UMWELTBUNDESAMT: *Klimawandel in der Antarktis*. <https://www.umweltbundesamt.de/themen/wasser/antarktis/die-antarktis/das-klima-der-antarktis/klimawandel-in-der-antarktis#eisschmelze-und-meeresspiegelanstieg>. Version: 2023. – Zugriff: 30.09.2024
- [3] EISEXPEDITIONEN.DE: *Eisberg A-23A*. <https://www.eisexpeditionen.de/blog/eisberg-a-23a>. Version: 2023. – Zugriff: 30.09.2024
- [4] EUROPEAN SPACE AGENCY (ESA): *Iceberg on the loose*. https://www.esa.int/ESA_Multimedia/Images/2023/12/Iceberg_on_the_loose. Version: 2023. – Zugriff: 30.09.2024
- [5] SINGH, Shivangini ; KUMAR, Shashi ; KUMAR, Navneet: Evolution of Iceberg A68 since Its Inception from the Collapse of Antarctica's Larsen C Ice Shelf Using Sentinel-1 SAR Data. In: *Sustainability* 15 (2023), Nr. 4. <http://dx.doi.org/10.3390/su15043757>. – DOI 10.3390/su15043757. – ISSN 2071–1050
- [6] KOO, Younghyun ; XIE, Hongjie ; MAHMOUD, Hazem ; IQRAH, Jordana M. ; ACKLEY, Stephen F.: Automated detection and tracking of medium-large icebergs from Sentinel-1 imagery using Google Earth Engine. In: *Remote Sensing of Environment* 296 (2023), 113731. <http://dx.doi.org/https://doi.org/10.1016/j.rse.2023.113731>. – DOI <https://doi.org/10.1016/j.rse.2023.113731>. – ISSN 0034–4257
- [7] SKOLNIK, Merrill I.: *Introduction to radar systems*. International student ed. New York [u.a : McGraw-Hill, 1962
- [8] KUNTZ, Prof. Dr. S.: *Introduction to Synthetic Aperture Radar (SAR) Technology and Spaceborne SAR Data Analysis*. <https://sso.uni-muenster.de/LearnWeb/learnweb2/course/view.php?id=70774>. Version: 2023. – Zugriff: 09.08.2024

- [9] LUDLOFF, A.K.: *Praxiswissen Radar und Radarsignalverarbeitung*. Vieweg+Teubner Verlag, 2013 <https://books.google.de/books?id=5Hb3BQAAQBAJ>. – ISBN 9783322995551
- [10] MOREIRA, Alberto ; PRATS-IRAOLA, Pau ; YOUNIS, Marwan ; KRIEGER, Gerhard ; HAJNSEK, Irena ; PAPATHANASSIOU, Konstantinos P.: A tutorial on synthetic aperture radar. In: *IEEE Geoscience and Remote Sensing Magazine* 1 (2013), Nr. 1, S. 6–43. <http://dx.doi.org/10.1109/MGRS.2013.2248301>. – DOI 10.1109/MGRS.2013.2248301
- [11] PARK, Daesung ; CHOI, Jaehoon: A Dual-Band Dual-Polarized Antenna with Improved Isolation Characteristics for Polarimetric SAR Applications. In: *Applied Sciences* 11 (2021), Nr. 21. <http://dx.doi.org/10.3390/app112110025>. – DOI 10.3390/app112110025. – ISSN 2076–3417
- [12] AGENCY, European S.: *S1 Mission*. <https://sentiwiki.copernicus.eu/web/s1-mission>, 2024. – Zugriff: 24.09.2024
- [13] AGENCY, European S.: *S1 Applications*. <https://sentiwiki.copernicus.eu/web/s1-applications>, 2024. – Zugriff: 24.09.2024
- [14] EUROPEAN SPACE AGENCY: *Sentinel-1: ESA’s Radar Observatory Mission for GMES Operational Services*. https://sentinel.esa.int/documents/247904/349449/S1_SP-1322_1.pdf. Version: 2012. – Zugriff: 24.09.2024
- [15] ECOSYSTEM, Copernicus Data S.: *Sentinel-1 Mission Overview*. <https://documentation.dataspace.copernicus.eu/Data/SentinelMissions/Sentinel1.html>. Version: 2024. – Zugriff: 24.09.2024
- [16] UMWELTBUNDESAMT: *Die Antarktis*. <https://www.umweltbundesamt.de/themen/nachhaltigkeit-strategien-internationales/antarktis/die-antarktis#undefined>. Version: 2023. – Zugriff: 30.09.2024
- [17] GORELICK, Noel ; HANCHER, Matt ; DIXON, Mike ; ILYUSHCHENKO, Simon ; THAU, David ; MOORE, Rebecca: Google Earth Engine: Planetary-scale geospatial analysis for everyone. In: *Remote Sensing of Environment* 202 (2017), 18–27. <http://dx.doi.org/https://doi.org/10.1016/j.rse.2017.06.031>. – DOI <https://doi.org/10.1016/j.rse.2017.06.031>. – ISSN 0034–4257. – Big Remotely Sensed Data: tools, applications and experiences
- [18] PARENTE, Leandro ; TAQUARY, Evandro ; SILVA, Ana P. ; SOUZA, Carlos ; FERREIRA, Laerte: Next Generation Mapping: Combining Deep Learning, Cloud Computing, and Big Remote Sensing Data. In: *Remote Sensing*

- 11 (2019), Nr. 23. <http://dx.doi.org/10.3390/rs11232881>. – DOI 10.3390/rs11232881. – ISSN 2072-4292
- [19] KUMAR, Lalit ; MUTANGA, Onesimo: Google Earth Engine Applications Since Inception: Usage, Trends, and Potential. In: *Remote Sensing* 10 (2018), Nr. 10. <http://dx.doi.org/10.3390/rs10101509>. – DOI 10.3390/rs10101509. – ISSN 2072-4292
- [20] QGIS: *QGIS*. <https://www.qgis.org/>, 2024. – Zugriff: 25.09.2024
- [21] MENKE, Kurt ; CROOK, Nicholas ; PIRELLI, Luigi ; HOESEN, John V.: *Mastering QGIS*. Birmingham, UK : Packt Publishing Ltd, 2016 <https://books.google.de/books?hl=de&lr=&id=jYdcDgAAQBAJ&oi=fnd&pg=PP1&dq=qgis&ots=FQfxsXk2Df&sig=RpNj3BWeTqmf3ljJCq5cnH3wil0#v=onepage&q&f=false>. – ISBN 9781787120262
- [22] GRASER, Anita ; PETERSON, Gretchen N.: *Learning QGIS*. Bend, OR, USA : Locate Press, 2015 <https://books.google.de/books?hl=de&lr=&id=rUXiCwAAQBAJ&oi=fnd&pg=PP1&dq=qgis&ots=SLgJdGULFN&sig=Czu2qfLWxkrLbA-d8o8QB4CwdcM#v=onepage&q=qgis&f=false>. – ISBN 9780989421762
- [23] CS, CNES .: *Orfeo Toolbox Documentation*. <https://www.orfeo-toolbox.org/CookBook/>. Version: 2024. – Zugriff: 06.08.2024
- [24] MANUEL GRIZONNET, Victor Poughon Jordi Inglada Mickaël S. Julien Michel M. Julien Michel ; CRESSON, Rémi: Orfeo ToolBox: open source processing of remote sensing images. In: *Open Geospatial Data, Software and Standards* 2 (2017), 15. <http://dx.doi.org/10.1186/s40965-017-0031-6>. – DOI 10.1186/s40965-017-0031-6
- [25] FILIPPONI, Federico: Sentinel-1 GRD Preprocessing Workflow. In: *Proceedings* 18 (2019), Nr. 1. <http://dx.doi.org/10.3390/ECRS-3-06201>. – DOI 10.3390/ECRS-3-06201. – ISSN 2504-3900
- [26] OLDELAND, Jens ; REVERMANN, Rasmus ; LUTHER-MOSEBACH, Jona ; BUTTSCHARDT, Tillmann ; LEHMANN, Jan R. K.: New tools for old problems — comparing drone- and field-based assessments of a problematic plant species. In: *Environmental Monitoring and Assessment* 193 (2021), 90. <http://dx.doi.org/10.1007/s10661-021-08852-2>. – DOI 10.1007/s10661-021-08852-2
- [27] ALPAYDIN, Ethem: *Maschinelles Lernen*. 3., aktualisierte und erweiterte Auflage. München ; Wien : De Gruyter Oldenbourg, 2022 (De Gruyter Studium). – ISBN 9783110740196

- [28] RUSSELL, Stuart J. ; NORVIG, Peter ; CHANG, Ming-wei: *Artificial intelligence*. Fourth edition, global edition. Harlow : Pearson, 2022 (Pearson series in artificial intelligence). – ISBN 9781292401133
- [29] RIGATTI, Steven J.: Random Forest. In: *Journal of Insurance Medicine* 47 (2017), 01, Nr. 1, 31-39. <http://dx.doi.org/10.17849/inism-47-01-31-39.1>. – DOI 10.17849/inism-47-01-31-39.1. – ISSN 0743-6661
- [30] MAHESH, Batta: Machine Learning Algorithms -A Review. In: *International Journal of Science and Research (IJSR)* 9 (2019), 01. <http://dx.doi.org/10.21275/ART20203995>. – DOI 10.21275/ART20203995
- [31] BIAU, Gérard ; SCORNET, Erwan: A random forest guided tour. In: *TEST* 25 (2016), 197-227. <http://dx.doi.org/10.1007/s11749-016-0481-7>. – DOI 10.1007/s11749-016-0481-7
- [32] GOODFELLOW, Ian ; BENGIO, Yoshua ; COURVILLE, Aaron: *Deep Learning*. MIT Press, 2016. – <http://www.deeplearningbook.org>
- [33] POWERS, David M W.: Evaluation: From precision, recall and F-measure to ROC, informedness, markedness and correlation. In: *Journal of Machine Learning Technologies* 2 (2011), Nr. 1, 37-63. <https://dl.acm.org/doi/10.5555/2123855.2123859>
- [34] COPERNICUS DATA SPACE ECOSYSTEM: *Sentinel-1 GRD Data — Copernicus Data Space Ecosystem Documentation*. <https://documentation.dataspace.copernicus.eu/APIs/SentinelHub/Data/S1GRD.html>. Version: 2024. – Zugriff: 30.09.2024
- [35] LEE, Jong-Sen ; WEN, Jen-Hung ; AINSWORTH, T.L. ; CHEN, Kun-Shan ; CHEN, A.J.: Improved Sigma Filter for Speckle Filtering of SAR Imagery. In: *IEEE Transactions on Geoscience and Remote Sensing* 47 (2009), Nr. 1, S. 202–213. <http://dx.doi.org/10.1109/TGRS.2008.2002881>. – DOI 10.1109/TGRS.2008.2002881
- [36] ORFEO TOOLBOX: *Large Scale Mean Shift — Orfeo Toolbox*. <https://www.orfeo-toolbox.org/Applications/LargeScaleMeanShift.html>. Version: 2024. – Zugriff: 30.09.2024
- [37] BUYUNGO, Jesse: *Object-based Image classification in QGIS*. YouTube-Video. <https://www.youtube.com/watch?v=fX2Up0woYLk>. Version: 2021. – Zugriff: 30.09.2024

Eidesstattliche Erklärung

Hiermit versichere ich, dass die vorliegende Arbeit über *„Teilautomatisierte Erfassung und Nachverfolgung des Eisbergs A23a von Januar 2022 bis Juni 2024 mittels Sentinel 1-SAR Daten“* selbstständig verfasst worden ist, dass keine anderen Quellen und Hilfsmittel als die angegebenen benutzt worden sind und dass die Stellen der Arbeit, die anderen Werken – auch elektronischen Medien – dem Wortlaut oder Sinn nach entnommen wurden, auf jeden Fall unter Angabe der Quelle als Entlehnung kenntlich gemacht worden sind.



Tim Lehmann, Münster, 2. Oktober 2024

Ich erkläre mich mit einem Abgleich der Arbeit mit anderen Texten zwecks Auffindung von Übereinstimmungen sowie mit einer zu diesem Zweck vorzunehmenden Speicherung der Arbeit in eine Datenbank einverstanden.



Tim Lehmann, Münster, 2. Oktober 2024